

Московский физико-технический институт

Лабораторная работа №2

Семантическая сегментация аэрофотоснимка с помощью сверточных нейронных сетей

Ярошевич Софья M01-504a

Долгопрудный
2026

1 Выбор данных и постановка задачи

В данной работе решалась задача сегментации фотоснимка поверхности Земли. Для анализа было выбрано изображение в формате .tif высокого разрешения (16423×11782 пикселей). На снимке представлены разнообразные объекты: лесные массивы, сельскохозяйственные поля, дорожная сеть и жилая застройка.

Для обучения модели были выделены 5 классов объектов: **Forest** (Лес), **Road** (Дорога), **Field** (Поле с рядами), **Grass** (Трава/Газон) и **House** (Дома).



Рис. 1: Исходное изображение аэрофотосъемки

2 Создание датасета и разметка

Процесс обучения нейросети требовал создания качественной обучающей выборки. Поскольку ручная разметка каждого пикселя на изображении такого разрешения является трудозатратной задачей, был применен метод «опорных фрагментов».

Многочисленными были вручную отобраны и размечены наиболее характерные и «чистые» участки для каждого из пяти классов. При выборе зон особое внимание уделялось тому, чтобы в обучающую выборку попали объекты при различном освещении и с разной текстурой (например, участки леса с густой тенью и открытые поля). Визуализация процесса разметки представлена на рис. 2.




Рис. 2: Пример ручного выделения опорных зон для формирования датасета

После определения координат этих зон, автоматизированный скрипт нарезал их на патчи размером 128×128 пикселей. В процессе формирования датасета был зафиксирован следующий объем данных по классам:

- **Field** (Поля): 11 668 патчей.
- **Grass** (Трава): 3 259 патчей.
- **Forest** (Лес): 1 767 патчей.
- **House** (Дома): 159 патчей.
- **Road** (Дороги): 48 патчей.

Такой разброс данных мог привести к переобучению модели в сторону мажоритарного класса (полей).

3 Методы борьбы с дисбалансом и обучение

Для обеспечения стабильного обучения нейросети были применены следующие стратегии:

1. **Балансировка выборки:** Количество патчей полей и травы было программно ограничено до 800 единиц.

2. **Аугментация данных:** Для редких классов (дороги и дома) применялись случайные повороты на 90, 180 и 270 градусов, а также горизонтальные и вертикальные отражения. Это позволило искусственно увеличить объем данных.
3. **Weighted Sampler:** В процессе обучения использовался весовой загрузчик данных (PyTorch WeightedRandomSampler), который чаще подавал на вход нейросети редкие фрагменты дорог.

В качестве архитектуры использовалась нейросеть **ResNet-18**. Обучение проводилось в течение 10 эпох, итоговая точность на обучающей выборке составила 97.8%. Примеры данных, на которых училась модель, представлены на рис. 3.



Рис. 3: Примеры сформированных обучающих патчей по классам

4 Результаты сегментации (Инференс)

В соответствии с заданием было исследовано влияние шага сканирования (step) на итоговую карту сегментации. Ниже приведены результаты обработки всего изображения при различных значениях шага.




Рис. 4: Результат сегментации при шаге сканирования $\text{step} = 256$. Наблюдается высокая дискретизация изображения и потеря мелких деталей.




Рис. 5: Результат сегментации при шаге сканирования $\text{step} = 128$. Оптимальный баланс между скоростью обработки и качеством выделения крупных объектов.




Рис. 6: Результат сегментации при шаге сканирования $\text{step} = 64$. Максимальная детализация границ объектов, плавные переходы между классами.

5 Выводы

Анализ полученных карт сегментации позволил сделать следующие выводы:

1. **Влияние параметров:** Уменьшение шага сканирования значительно повышает визуальное качество маски, однако кратно увеличивает время вычислений. Шаг 64 пикселя является наиболее предпочтительным для финального анализа.
2. **Качество распознавания:** Нейросеть безошибочно сегментирует природные зоны (лес и поля) благодаря их специфической текстуре.
3. **Ошибки классификации:** Наблюдается смешивание классов «Дорога» и «Дом» (красная маркировка на дорожном полотне). Это связано с визуальным сходством материалов (асфальт и бетонные/шиферные крыши), а также с острым дефицитом обучающих примеров для дорог в исходном датасете.

В целом, реализованный подход на базе ResNet-18 показал высокую эффективность для автоматизированного анализа аэрофотоснимков большой площади.